



Cartes postales du Vaucluse



Objectifs & corpus

- 3000 cartes postales
- Métadonnées sur le [site des Archives départementales](#)
- “Les Archives de Vaucluse souhaiterait obtenir une cartographie, à partir de laquelle, en cliquant sur la commune ou sur un lieu/édifice, la carte postale apparaîtrait, accompagnée de métadonnées descriptives (notamment le nom et la date).”



Pipeline

ÉTAPE 1 : OCR ET INDEXATION (QWEN3 VL (8B))

- On donne les cartes postales au VLM
- Il occrise le texte
- À partir du texte extrait, il propose une commune, un lieu-dit et un monument

ÉTAPE 2 : RECHERCHES DES LIEUX MENTIONNÉS ET CRÉATION DU JSON (QWEN3 VL (8B) + MERIMEE API + TOPO API + DUCKDUCKGO SEARCH)

- Normalisation du texte
- Interrogation de la base MERIMEE (monuments)
- Interrogation de la base TOPO (lieux-dits)
- Recherche des lieux identifiés avec QWEN + DuckDuckGo_Search

ÉTAPE 3 : SCRAPPING DES MÉTADONNÉES (Selenium)

- Échec du scrapping en User-Agent (« You got banned permanently from this server »)
- Avec Selenium on récupère les pages HTML, nom exact de la photo, autres informations
- On trie avec des regex
- On merge le fichier de métadonnées avec le JSON établi à l'étape précédente

ÉTAPE 4 : GÉORÉFÉRENCEMENT (Nominatim API)

- Test d'OSMnx et de Mistral
- On interroge Nominatim à partir des données qu'on obtient.
- Stratégie d'interrogation du plus au moins précis :
- 1 : Chercher avec les monuments issus de la recherche DuckDuckGo
- 2 : Chercher les édifices inscrits dans les metadonnées
- 3 : Chercher les lieux-dits issus de la recherche DuckDuckGo
- 4 : Prendre les coordonnées de la commune

ÉTAPE 5 : CRÉATION D'UNE CARTE HTML (Folium)

- Chargement d'un fond de carte OpenStreetMap
- Importation des points géoréférencés et création de clusters pour que le carte ne soit pas trop difficile à charger
- Ajout des métadonnées (dont une image de la carte) en pop up
- Création d'un outil de gestion de couches (en fonction de la date)
- Respect de la charte graphique

Difficultés

```
headers= {"User-Agent": "Mozilla/5.0"}
response = requests.get("https://earchives.vaucluse.fr/archives/show/FRAD6
print(response.text)
```

You got banned permanently from this server.

- Utilisation de bdd avec Qwen : 1 - base TOPO / base Fantoir pour les lieux-dits avec API ou avec .json nettoyé, 2 - base Mérimée API ou .json
→ résolu par l'utilisation de la recherche internet avec duckduckgo et Qwen (mais moins exact !?)
- Connexion Internet à l'École
→ câble Ethernet
- Nécessité de scraper avec Selenium (merci Alexandre)
- Géoréférencement via le cadastre ou osmnx assez moyen
→ nomitim
- Carto : nous n'avons pas réussi à intégrer frontières communes ni départements

Industrialisation sur nos 3000 cartes :

- Utilisation du GPU de l'école pour nos deux premières étapes avec Qwen3 VL dans la nuit de jeudi à vendredi (merci Chahan)
- Malheureusement erreur dans notre fichier python, seulement 84 cartes ont été traitées
→ nécessité de modifier notre script

Résultats & perspectives

Résultats Qwen3 VL / annotation manuelle :

- Ville : peu d'erreurs étant donné qu'on fournissait la liste des communes du Vaucluse sauf cartes postales sur lesquelles rien à noter
- Lieu-dit : peu d'erreurs qd il n'y a pas de lieu-dit. Sinon confusion parfois avec monuments
- Monument : ne donne souvent qu'une partie de tout l'intitulé du monument, exp dans : "Cathédrale Sainte-Anne - Crypte intérieure", ne renverra que "Crypte intérieure"

Rendu :

- Récupération des métadonnées disponibles sur le site de toutes les cartes avec ajout coordonnées des communes pour toutes les cartes
→ on peut faire une carte où toutes les cartes postales sont placées sur leur commune
- Carte interactive pour 84 cartes postales avec géoréférencement monument/lieu-dit

Perspectives :

- Évaluer géoréférencement nominatif
- Industrialiser baseline sur corpus entier
- Réussir à exploiter les bdd pour meilleure précision en évitant faux positifs
- Géoréférencement précision geoguessr par Mathias

